

מבוא למערכות לומדות - תרגיל 1

מגיש: יואב לוי 314963257

שאלה 1

$$v = (1, 2, 3, 4), \quad w = (0, -1, 1, 2)$$

$$\text{The projection of } v \text{ on } w \text{ will be: } p = \frac{\langle v, w \rangle}{\|w\|^2} \cdot w = \frac{3}{2} \begin{bmatrix} 0 \\ -1 \\ 1 \\ 2 \end{bmatrix}$$

שאלה 2

$$v = (1, 2, 3, 4), \quad w = (1, 0, 1, -1)$$

$$\text{The projection of } v \text{ on } w \text{ will be: } p = \frac{\langle (1, 2, 3, 4), (1, 0, 1, -1) \rangle}{\|(1, 0, 1, -1)\|^2} \cdot w = \vec{0}$$

שאלה 3

הוכחה: נתונים שני ווקטורים $\vec{0} \neq v, w \in \mathbb{R}^m$.

נסמן ב- θ את הזווית בין שני הווקטורים שלעיל.

(\Leftarrow) נניח כי $\langle v, w \rangle = 0$ ולפי הגדרה גם מתקיים כי $0 = \langle v, w \rangle = \|v\| \cdot \|w\| \cdot \cos(\theta)$ מהנתון כי שני הווקטורים אינם וקטורי האפס אזי בהכרח $\cos(\theta) = 0 \iff \theta = \pm\pi = \pm 90^\circ$ כנדרש.

(\Rightarrow) נניח כי $\theta = \pm 90^\circ$, כעת $\langle v, w \rangle = \|v\| \cdot \|w\| \cdot \cos(90) = 0$ וגם

$\langle v, w \rangle = \|v\| \cdot \|w\| \cdot \cos(-90) = 0$ כנדרש.

■

שאלה 4

$$\|Ax\|_2^2 = \langle Ax | Ax \rangle \stackrel{\text{dot product definition}}{=} (Ax)^T Ax = (x^T A^T) Ax \stackrel{A^t = A^{-1} \text{ Orthogonal matrix}}{=} x^T Ix = \langle x | x \rangle = \|x\|_2^2$$

ולכן,

$$\|Ax\|_2 = \|x\|_2$$

שאלה 5

$$A = UDV^T \implies A^{-1} = VD^{-1}U^{-1}$$

בעזרת ה-SVD ניתן להכפיל את A או את A^{-1} בחזקה גדולה במהירות, מכיוון שלהעלות בחזקה מטריצה אלכסונית זה קל (האלכסון עולה בחזקה).

שאלה 6

נשים לב כי $C^T C = VD^2 V^T$ מטריצה סימטרית,

$$M \equiv C^T C = \begin{pmatrix} 5 & 5 \\ -1 & 7 \end{pmatrix} \cdot \begin{pmatrix} 5 & 5 \\ -1 & 7 \end{pmatrix} = \begin{pmatrix} 26 & 18 \\ 18 & 74 \end{pmatrix}$$

ממשפט הפירוק הספקטרלי המטריצה הזו ניתנת ללכסון אורתוגונלי, לכן נלכסן אותה אורתוגונלית וכך נמצא את V, D^2 .

- משווים את הפולינום האופייני לאפס ומוצאים את הפתרונות של λ .

$$\det(\lambda I - M) = \begin{vmatrix} \lambda - 26 & -18 \\ -18 & \lambda - 74 \end{vmatrix} = (\lambda - 26) \cdot (\lambda - 74) - 324 = 0 \iff \lambda^2 - 100\lambda + 1600 = 0$$

לכן ה-Eigenvalues (=ערכים עצמיים) הם: $\lambda_1 = 20, \lambda_2 = 80$. (python » w, v = numpy.linalg.eig([[26,18],[18,74]])

- נמצא את הווקטורים העצמיים.

$$V_{20} : (20I - M)v = 0 \iff \begin{pmatrix} 20 - 26 & -18 \\ -18 & 20 - 74 \end{pmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \iff v_1 = \begin{bmatrix} -3 \\ 1 \end{bmatrix}$$

$$V_{80} : (80I - M)v = 0 \iff \begin{pmatrix} 80 - 26 & -18 \\ -18 & 80 - 74 \end{pmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \iff v_2 = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$$

- נפעיל את אלגוריתם GS=Gram-schmidt למציאת בסיס אורתונורמלי ובכך נמצא את V (המטריצה המלכסנת)

ננרמל את הווקטור v_1

$$u_1 = \frac{v_1}{\|v_1\|_2} = \frac{\sqrt{10}}{10} \begin{bmatrix} -3 \\ 1 \end{bmatrix}$$

כעת,

$$b_2 = v_2 - \langle v_2, u_1 \rangle u_1 = \begin{bmatrix} 1 \\ 3 \end{bmatrix} \Rightarrow u_2 = \frac{b_2}{\|b_2\|_2} = \frac{\sqrt{10}}{10} \begin{bmatrix} 1 \\ 3 \end{bmatrix}$$

לכן,

$$V = \begin{pmatrix} -\frac{3\sqrt{10}}{10} & \frac{\sqrt{10}}{10} \\ \frac{\sqrt{10}}{10} & \frac{3\sqrt{10}}{10} \end{pmatrix} \in M_{3,3}(\mathbb{R})$$

• כמובן שגם המטריצה האלכסונית D^2 הינה,

$$D^2 = \begin{pmatrix} 20 & 0 \\ 0 & 80 \end{pmatrix} \in M_{3,3}(\mathbb{R})$$

בלי הגבלת הכלליות (מכיוון שהפירוק SVD אינו יחיד) נקבל

$$D = \begin{pmatrix} 2\sqrt{5} & 0 \\ 0 & 4\sqrt{5} \end{pmatrix}$$

עכשיו מכיוון ש- $C = UDV^T \iff CV = UDV^{-1}V = UD$ אז,

$$CV = \begin{pmatrix} 5 & 5 \\ -1 & 7 \end{pmatrix} \cdot \begin{pmatrix} -\frac{3\sqrt{10}}{10} & \frac{\sqrt{10}}{10} \\ \frac{\sqrt{10}}{10} & \frac{3\sqrt{10}}{10} \end{pmatrix} = \begin{pmatrix} a_{1,1} & a_{1,2} \\ a_{2,1} & a_{2,2} \end{pmatrix} \cdot \begin{pmatrix} 2\sqrt{5} & 0 \\ 0 & 4\sqrt{5} \end{pmatrix} = UD$$

\Updownarrow

$$\begin{pmatrix} -\sqrt{10} & 2\sqrt{10} \\ \sqrt{10} & 2\sqrt{10} \end{pmatrix} = \begin{pmatrix} 2\sqrt{5}a_{1,1} & 4\sqrt{5}a_{1,2} \\ 2\sqrt{5}a_{2,1} & 4\sqrt{5}a_{2,2} \end{pmatrix}$$

כלומר,

$$U = \begin{pmatrix} -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{pmatrix}$$

הערה: נשים לב כי המטריצה סימטרית (וההופכית שלה היא המטריצה המשוכללת ולכן היא אוניטרית\אורתוגונלית) ולבסוף הפירוק SVD יהיה:

$$C = \begin{pmatrix} -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{pmatrix} \cdot \begin{pmatrix} 2\sqrt{5} & 0 \\ 0 & 4\sqrt{5} \end{pmatrix} \cdot \begin{pmatrix} -\frac{3\sqrt{10}}{10} & \frac{\sqrt{10}}{10} \\ \frac{\sqrt{10}}{10} & \frac{3\sqrt{10}}{10} \end{pmatrix} = \begin{pmatrix} 5 & 5 \\ -1 & 7 \end{pmatrix}$$

שאלה 7

יהיו $\lambda_1, \lambda_2, \dots, \lambda_n \in \mathbb{R}$ הערכים העצמיים של המטריצה $C_0 := A^T A$ ו- v_1, v_2, \dots, v_n הווקטורים העצמיים המתאימים להם. נניח בלי הגבלת הכלליות כי $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$. בהנחה ש- $\lambda_1 > \lambda_2$, אז נשים לב שמתקיים:

$$b_{k+1} = \frac{C_0 b_k}{\|C_0 b_k\|} = \frac{C_0^{k+1} b_0}{\|C_0^{k+1} b_0\|} \stackrel{b_k := \sum_{i=1}^n a_i v_i}{=} \frac{C_0^{k+1} \sum_{i=1}^n a_i v_i}{\|C_0^{k+1} \sum_{i=1}^n a_i v_i\|} \stackrel{v_1, \dots, v_n \text{ corresponding eigenvectors}}{=} \frac{\lambda_1^{k+1} \sum_{i=1}^n \left(\frac{\lambda_i}{\lambda_1}\right)^{k+1} a_i v_i}{\left\| \lambda_1^{k+1} \sum_{i=1}^n \left(\frac{\lambda_i}{\lambda_1}\right)^{k+1} a_i v_i \right\|} =$$

ומכאן, ומהנתון כי λ_1 הוא הערך העצמי הדומיננטי (גדול) ביותר, נקבל כי:

$$\lim_{k \rightarrow \infty} b_k = \frac{\lambda_1^{k+1}}{\|\lambda_1^{k+1} v_1\|} v_1 = \frac{v_1}{\|v_1\|}$$

■

שאלה 8

$$f(\sigma) = \sum_{i=1}^n \sigma_i u_i u_i^T x \quad \text{where } u_i \text{ is the } i\text{'th column of matrix } U$$

כעת, איבר בשורה ה- k ובעמודה ה- i במטריצת היעקוביאן תראה כך:

$$\frac{\partial f_k(\sigma_{\text{const}})}{\partial \sigma_i} = [u_i u_i^T x]_k$$

שאלה 9

$$h(\sigma) = \frac{1}{2} \|f(\sigma) - y\|^2$$

אגדיר את הפונקציות הבאות:

$$g(x) = \|x\|^2$$

$$w(\sigma) = f(\sigma) - y$$

נשים לב כי מתקיים $h(\sigma) = \frac{1}{2} g \circ (w(\sigma))$. נשים לב כי מתקיים $h(\sigma) = \frac{1}{2} g \circ (w(\sigma))$. כעת, לפי כלל השרשרת שראינו בתרגול על יעקוביאן (=לגרדיאנט בפונקציות מווקטור לסקלר)

$$J_{\sigma} \left(\frac{1}{2} g \circ (w(\sigma)) \right) = \frac{1}{2} J_{\sigma} (g \circ (w(\sigma))) \stackrel{\text{chain rule}}{=} \frac{1}{2} \overbrace{J_{w(\sigma)}(g)}^{\blacktriangledown} \cdot \overbrace{J_{\sigma}(w)}^{\blacktriangle} = \frac{1}{2} \cdot \overbrace{2(f(\sigma) - y)^T}^{\blacktriangledown} \cdot \overbrace{\nabla f(\sigma)}^{\blacktriangle}$$

כלומר,

$$\nabla h(\sigma) = (f(\sigma) - y)^T \nabla f(\sigma)$$

שאלה 10

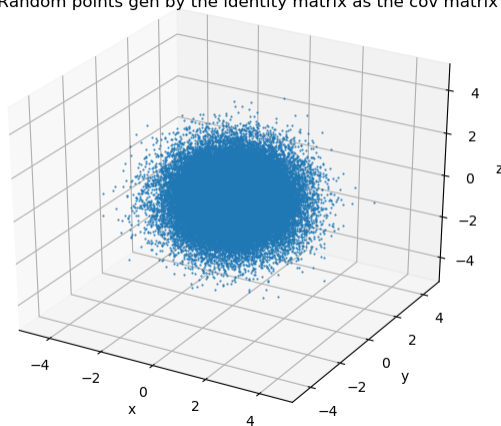
חישוב היעקוביאן של פונקציית ה-softmax (נשים לב שהמשכתי את השלבים הראשונים שהופיעו בתרגול ולכן רוב המלל הוסר)

$$\frac{\partial g_i(z)}{\partial z_j} = g_i(z) (\delta_{ij} - g_j(z))$$

שאלה 11

גרף הנתונים:


Q11: Random points gen by the identity matrix as the cov matrix



שאלה 12

גרף הנתונים לאחר הפעלת טרנספורמציה לינארית:

Q12: Linear Transformed the prev data



בנוסף מטריצת השונות המשותפת ("Covariance matrix") תהיה:
צורה נומרית

$$C = \begin{pmatrix} 0.00995852 & 0.00030081 & -0.00073439 \\ 0.00030081 & 0.25066825 & -0.00314623 \\ -0.00073439 & -0.00314623 & 4.00677747 \end{pmatrix}$$

צורה אנליטית


(כאשר דגמנו 50,000 דגימות, והן מיוצגות במטריצה X ומטריצת השונות המשותפת המקורית היא \hat{C})

$$C := \frac{SX(SX)^T}{50000 - 1} = S \frac{XX^T}{49999} S^T = S\hat{C}S^T$$

שאלה 13

גרף הנתונים לאחר הפעלת טרנספורמציה לינארית ואז הפעלת מטריצה אורתוגונלית:

Q13: Applied orthogonal matrix




מטריצת השונות המשותפת תהיה:

$$C = \begin{pmatrix} 0.24479533 & -0.02450719 & 0.05942625 \\ -0.02450719 & 2.64547029 & -1.84138481 \\ 0.05942625 & -1.84138481 & 1.30421308 \end{pmatrix}$$


שאלה 14

הגרף שמייצג את ההטלה של ה-Data על המישור x, y הוא:




שאלה 15

הגרף שמייצג את ההטלה של ה-Data שמקיים $0.1 > z > -0.4$ על המישור x, y :



שאלה 16

(א) אני מצפה לראות התכנסות לממוצא ככול שמספר ההטלות הולך וגדל (לפי החוק החלש של המספרים הגדולים), ואכן בגרף ניתן לראות זאת בבירור.



(B)+(C)

הסבר עבור סעיף c: אני מצפה לראות שהממוצע רחוק מהתוחלת בניסויים שלנו תרד ככל שמספר הזריקות עולה, כלומר ככל שאנחנו זורקים יותר כך המרחק שנתון בסעיף c יהיה קטן יותר וכך אחוז הניסויים שהיו רחוקים מאפסילון תקטן.

כמו כן כאשר אפסילון גדול יחסית, כך נגיע מהר יותר לאחוז 0, וההפך.

